VLA技术调研

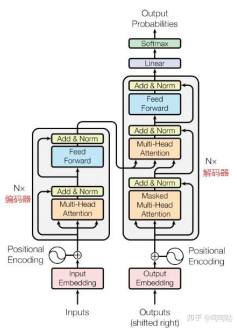
1. 概览

1.1 什么是VLA，与VLM/LLM、端到端之间的关系

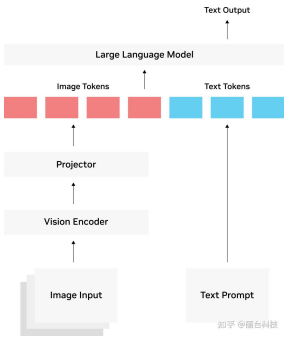
> VLA（Vision-Language-Action Model），
>
> 差异：将Action作为模型的直接输出

VLA（Vision-Language-Action Model）是一种融合视觉感知、语言理解和动作执行的多模态大模型，旨在通过类人思维链推理（Chain of Thought, CoT）实现与物理世界的智能交互。其核心目标是将AI从“被动辅助工具”升级为“主动生产工具”，在自动驾驶、机器人等领域实现高度拟人化的决策与执行能力

结构差异性



LLM（tranformer



VLM

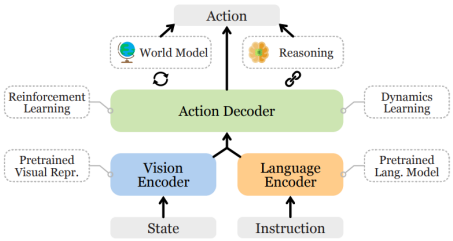


Figure 1: The general architecture of vision-language-action models. Important related components are shown in the dashed-line boxes.

VLA



VAL示例

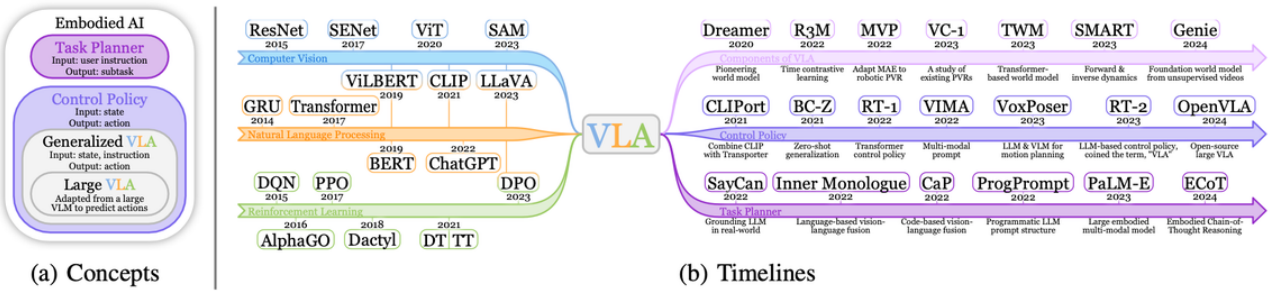
VLM VS VLA

特性	VLM（视觉语言模型）	VLA（视觉语言动作模型）
目标	感知 + 推理 + 对话	感知 + 推理 + 执行动作
输入	图像/视频 + 文本	图像/视频 + 文本 + 历史状态
输出	文本回答 / 标签 / 特征	可执行动作（离散或连续）
应用	图文问答、图像生成、图像字幕、视觉问诊等	Web操作、机器人控制、人机交互、桌面自动化等
示例模型	CLIP, BLIP-2, Flamingo, GPT-4V	RT-1, RT-2, SayCan, VIMA, Gato, HULC
推理机制	语言生成 / 多模态对齐	行为决策（策略输出）
优势	多模态理解强，易用，训练数据丰富	能完成**真实世界任务**，体现智能体能力
劣势	无法完成实际操作，停留在理解层面	训练难度高，安全要求高，泛化困难

1.2 为什么一定要选择VLA?

> 没有一定，是一种螺旋式发展的趋势； 1）上限更高； 2）技术成熟度；
>
> 2023.7 google推出的RT-2才受到大家的关注。
>
> 新技术的发展有很大不确定性，diffusion/transformer

相关技术的成熟



(a) Concepts (b) Timelines

Figure 2: (a) A Venn diagram that outlines the main concepts in embodied AI discussed in this paper. (b) Timelines that trace the evolution from unimodal models to vision-language-action models.

技术方向	代表突破	支撑能力
视觉理解	CLIP, DINOv2, SAM	感知与对象识别
多模态对齐	BLIP-2, Flamingo, LLaVA	图文语义融合
大语言模型	GPT-4, PaLM-2	指令理解与任务计划
语言到行动	SayCan, ACT, Instruct2Act	行为映射
执行动作	RL控制器、GUI Agent、机器人	实际交互操作
模拟与交互环境	AI2-THOR, Habitat	数据采集与闭环训练

1.3 有哪些挑战和阻碍?（智驾）

> 不成熟：数据少，模态对齐难，复杂度高
>
> 车的场景
>
> - 训练数据少： Vision(pic,sensor,lastaction) -> next Action
> - 模态对齐： Vision，（时序）, Action 的对齐
> - 复杂度高：将更多功能集成到一个模型里

1.3.1 数据不足

1. 量级与多样性不足：数据量级远不及训练视觉 - 语言模型（VLM）的数据，且多样性严重不足，多采集于简单环境。存在 “数据不足限制模型能力、模型能力有限制约数据采集” 的恶性循环。
2. 数据采集难题：在实际应用中，获取高质量、多样化且适用于 VLA 训练的数据存在困难，阻碍模型性能提升。

1.3.2 多模态对齐

涉及图像、实践、3D空间、动作的对齐

- 图像、语言和动作是异质模态，表示空间不同步
- 输入变化极大（比如按钮视觉变化、语言歧义），难以正确对齐动作输出
- 时序和空间理解要求高，尤其在“操作”中必须精准定位+预测动作时机

1.3.3 复杂度升高

- 三模态联合建模 + 长时序推理，导致模型参数爆炸、推理速度变慢
- 训练流程需要同步图像处理、语言理解、动作预测，pipeline复杂
- 模型难以部署在低功耗设备或实时任务场景中

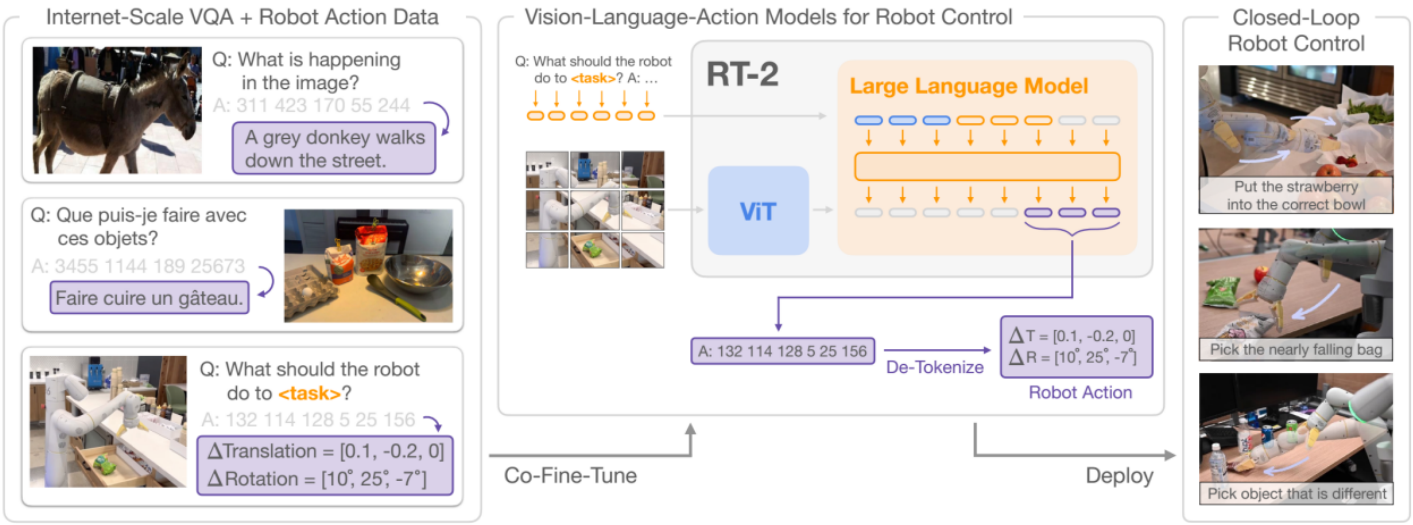
2. 典型模型架构

2.1 技术分类

路线类型	简述	代表模型	技术关键点
行为克隆（BC）路线	从人类示范中学习感知-语言-动作映射	RT-1 / RT-2 / HULC	多模态行为建模 + 大规模示范数据
语言规划 + 动作执行（分层控制）	语言模块生成高层意图，动作模块执行	SayCan / InnerMonologue	LLM + Value Function + 动作执行接口
多模态端到端（E2E）强化学习	将图像+语言直接映射为动作，通过强化学习优化	Gato / VIMA	跨模态输入融合 + RL 策略优化
仿真驱动模仿学习	使用仿真器生成训练数据，训练泛化控制策略	VRL3 / RoboRT-1	模仿学习 + 仿真环境迁移
Diffusion Policy 路线	使用扩散模型生成动作轨迹，适合高维动作	Diffusion-Action, ActDiff	动作作为概率分布建模，具备生成多样性

2.2 开山之作RT-2框架

2023.7谷歌DeepMind推出了一款新的机器人模型Robotics Transformer 2,RT-2 模型的核心创新点主要体现在模型架构设计和能力突破两方面，通过融合互联网级视觉 - 语言数据与机器人控制，实现了机器人泛化能力和语义推理能力的显著提升。



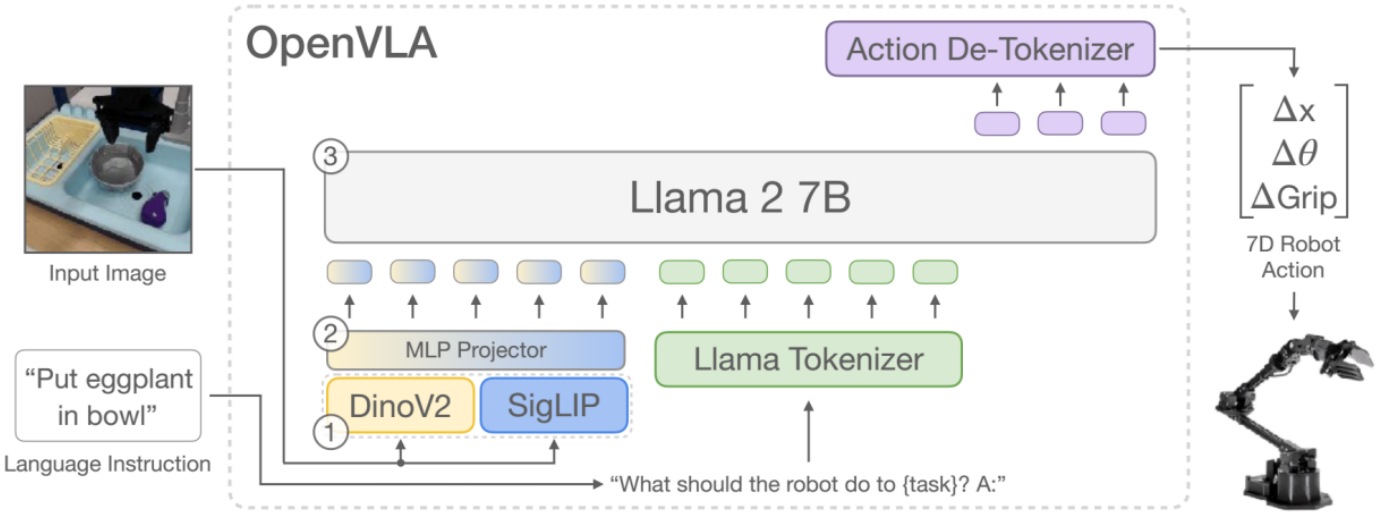
论文《RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control》

2.2.3 创新点-（视觉 - 语言 - 动作模型（VLA）的统一表示）

1. 动作文本化编码
   - 将机器人的动作（如关节角度、末端执行器指令等）转化为文本 tokens，与自然语言指令、视觉信息统一输入模型。（例如将 “移动机械臂至坐标 (x,y,z)” 表示为特定文本序列）
   - 优势：无需为动作设计独立的解码模块，直接复用视觉 - 语言模型（如 PaLM-E）的现有架构，简化训练流程并增强跨模态对齐能力。
2. 联合微调策略
   - 在训练阶段同时使用机器人轨迹数据（如操纵物体的动作序列）和互联网级视觉 - 语言任务（如视觉问答、图像描述）。
   - 目标：通过大规模非结构化数据（网页图文）增强模型的语义理解能力，同时通过机器人数据保留控制精度。

2.3 OpenVLA框架-首个完全开源的VLA模型

丰田、谷歌、斯坦福、UC巴克利合作的OpenVLA，它公布于2024年3月, OpenVLA 是一个开源视觉 - 语言 - 动作模型，于 2024 年 6 月 13 日发布，含 70 亿参数，在 97 万真实机器人演示数据上训练而成，基于 Llama 2 语言模型与融合 DINOv2 和 SigLIP 预训练特征的视觉编码器构建；其在 29 项任务中绝对任务成功率比 RT-2-X（550 亿参数）高 16.5%，参数少 7 倍，在多任务环境泛化和语言接地能力表现强，优于 Diffusion Policy 20.4%；还可通过现代低秩适应方法在消费级 GPU 上微调，经量化后有效部署，同时开源了模型检查点、微调笔记本和 PyTorch 代码库，支持在 Open X-Embodiment 数据集大规模训练 VLA 模型。



创新点

- 打破封闭生态：现有主流 VLA 模型（如 RT-2、RT-2-X）多为企业闭源方案，公众无法获取模型参数或代码。OpenVLA 首次开源70 亿参数的 VLA 模型，并提供完整训练框架，推动学术界和工业界对 VLA 的研究与应用。
- 降低技术门槛：开源资源（模型检查点、微调笔记本、PyTorch 代码库）使开发者无需从头训练，可直接基于预训练模型快速定制机器人技能，加速技术落地。

2.4 OpenDriveVLA: Towards End-to-end Autonomous Driving with Large Vision Language Action Model

Technical University of Munich 这是一种专为端到端自动驾驶设计的视觉 - 语言 - 动作（VLA）模型，其核心思想是通过融合视觉感知、语言理解和动作生成能力，实现基于环境语义的端到端自动驾驶决策

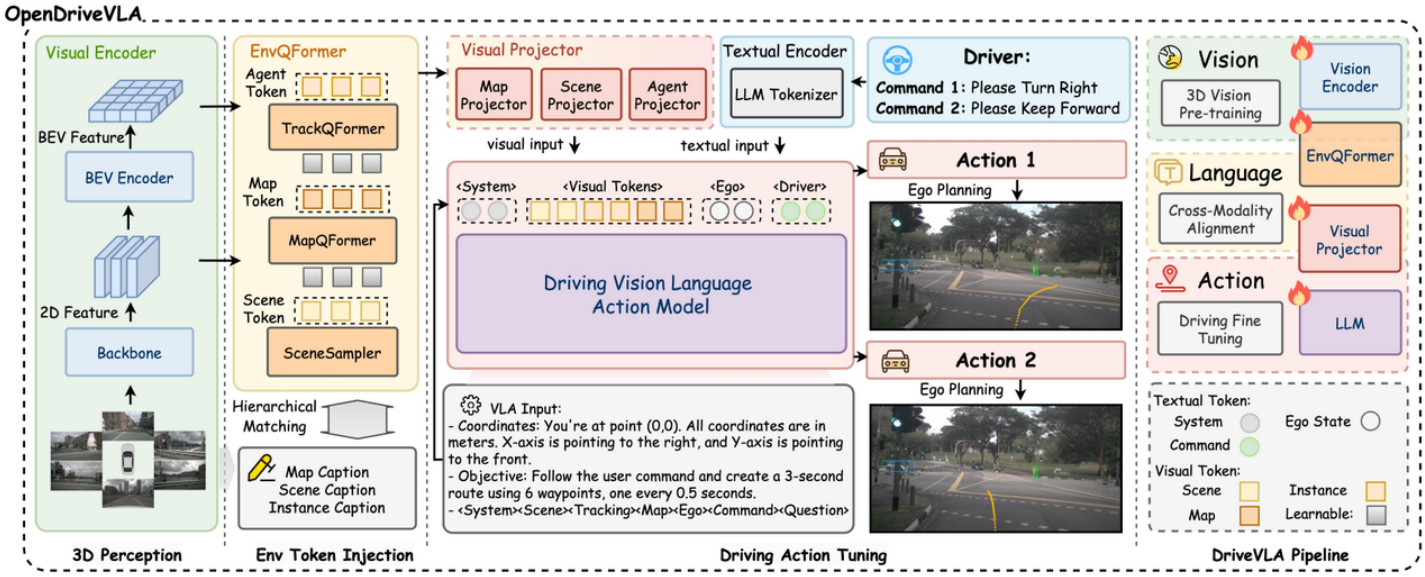
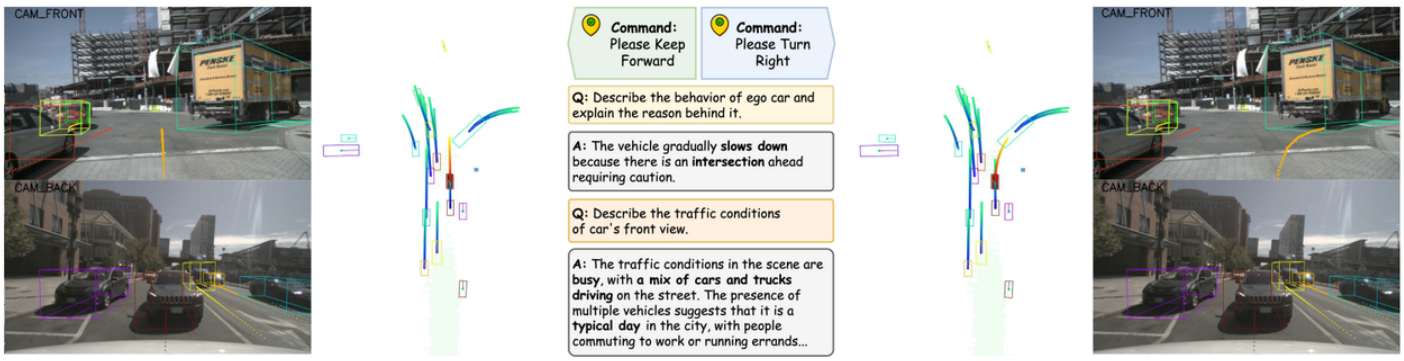


Figure 1. OpenDriveVLA leverages open-source pre-trained language foundation models to generate driving actions conditioned on 3D environmental perception, ego vehicle states, and driver commands. It achieves leading performance in both open-loop planning and driving-related question answering, demonstrating its proficiency in driving action planning and scene understanding.

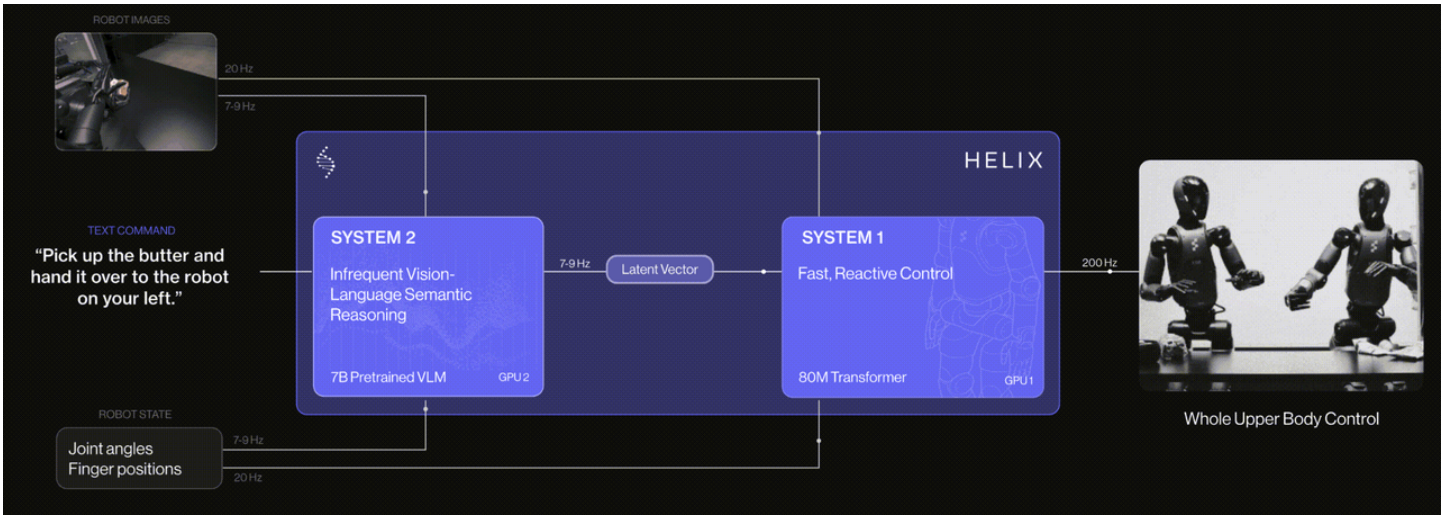


关键技术创新

- 层次化视觉 - 语言对齐：
  提出一种层次化对齐方法，将2D 图像视觉特征和3D 结构化视觉标记（如激光雷达点云生成的 BEV 特征）投影到统一语义空间，解决驾驶视觉表征与语言嵌入之间的模态差异，使模型能将视觉感知与语言指令直接关联。
- 自回归代理 - 环境 - 自车交互建模：
  通过自回归机制建模自车、周围智能体（如其他车辆、行人）和静态道路元素之间的动态关系，确保轨迹规划同时考虑空间位置（如避免碰撞）和行为逻辑（如遵守交通规则、预测其他车辆意图），实现更安全、合理的路径规划。

2.5 Helix: A Vision-Language-Action Model for Generalist Humanoid Control

2025年2月20日，智能机器人公司 Figure.AI 发布的 VLA 模型 “Helix: A Vision-Language-Action Model for Generalist Humanoid Control”，是典型的快慢双系统，也是最接近量产的机器人VLA系统，Figure.AI在机器人领域的地位近似于OpenAI在LLM领域内的地位。



首先来看Helix的神奇之处，第一是快，(RT-2论文里提到的决策频率则只有1到5hz)，更没法做到200hz的操作速度，Helix的上一代Figure 01中得益于基于简单神经网络的机器人操控小模型，做到了以 200hz 的频率生成 24-DOF 动作(在自由度上，Helix有35自由度)，RT-2还是6自由度。第二是简单，就一个大模型，通过自然语言就可得到最终的 Action。第三是训练效率高，现有的 VLA 系统通常需要专门的微调来优化不同高级行为的性能，Helix则不用。第四，泛化能力强，Helix 直接输出高维动作空间的连续控制，避免了先前 VLA 方法中——比如RT-2、OpenVLA使用的相对简单的离散化动作tokenization方案，已取得一些成功，但在高维人形控制中面临扩展挑战。第五，所需训练数据少，收集了高质量的多机器人、多操作员数据集，其中包含各种远程操作行为，使用约 500 小时的高质量监督数据来训练 Helix，而一般的VLA预训练数据集一般1万小时起步。

2.6 A Dual Process VLA: Efficient Robotic Manipulation Leveraging VLM

这篇文章提出了一种双过程视觉 - 语言 - 动作模型（DP-VLA），旨在解决现有 VLA 模型在实时性能方面的计算瓶颈问题

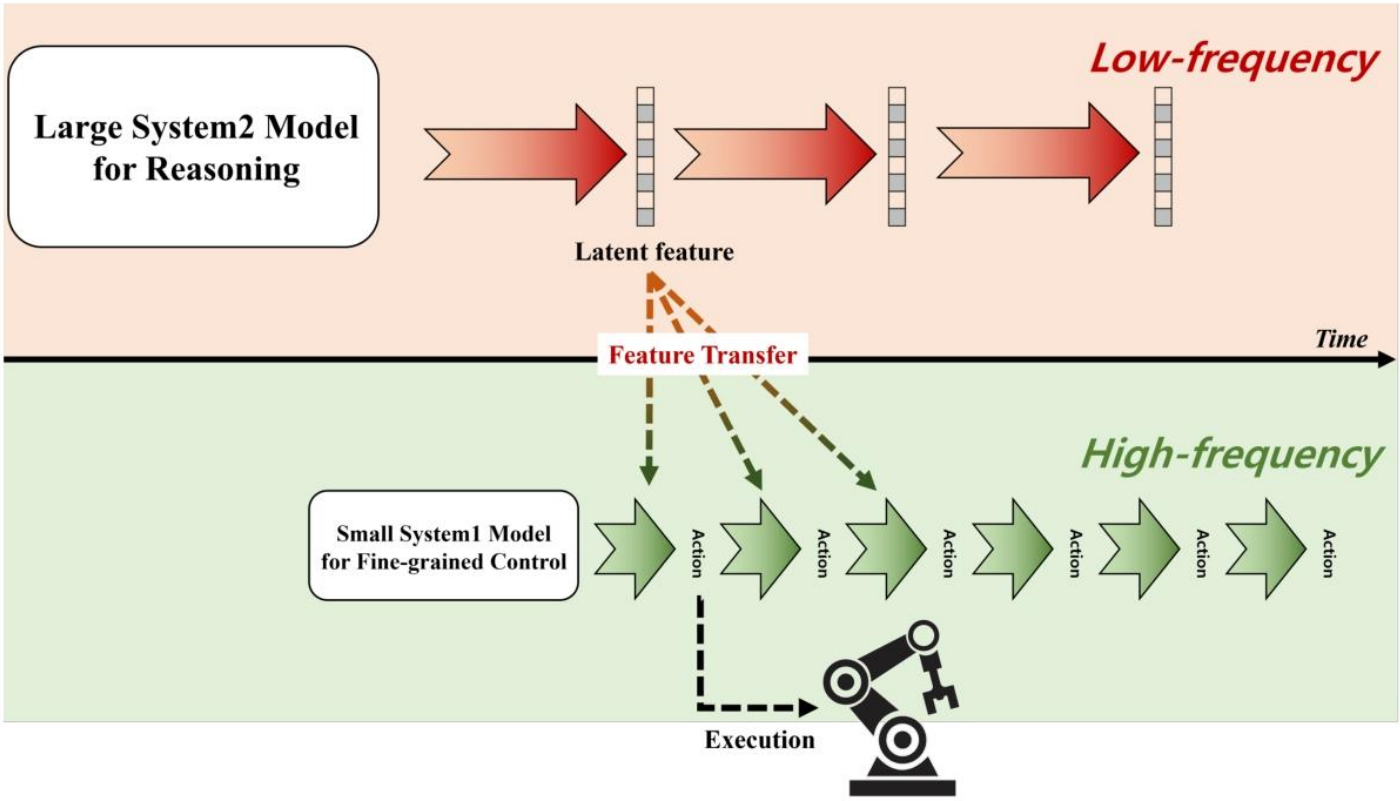
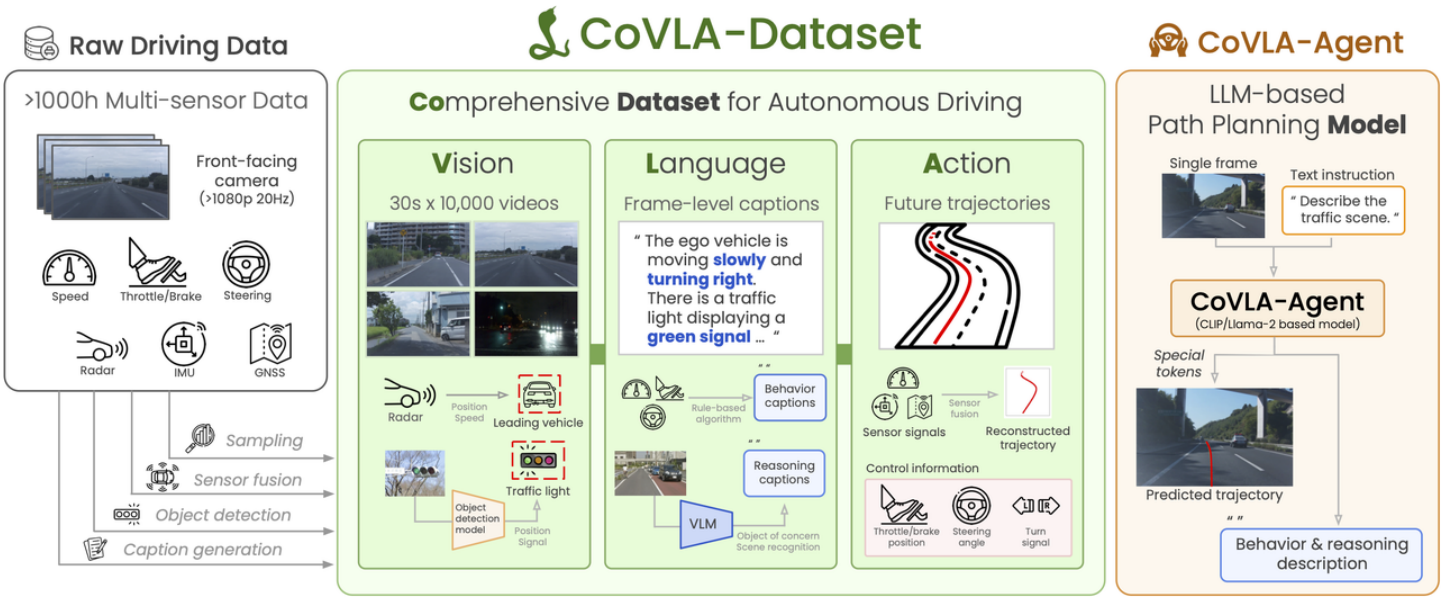


Figure 1: Our Dual Process framework integrates the concepts of System 2 and System 1. The Large System 2 Model (L-Sys2) extracts latent features that encode both reasoning information related to user instructions

2.7 CoVLA: Comprehensive Vision-Language-Action Dataset for Autonomous Driving

这篇文章的核心创新点聚焦于构建大规模多模态数据集与开发端到端自动驾驶模型，旨在解决自动驾驶中 “长尾” 场景的复杂推理与规划问题。



技术关键点总结

1. 提出 CoVLA 数据集：首个融合视觉 - 语言 - 动作的大规模自动驾驶数据集

- 多模态数据融合与规模突破

- 包含10,000 个真实驾驶场景（总计超 80 小时视频），涵盖城市道路、高速公路、雨天、夜间等多样化环境。
- 每个场景同步整合前视摄像头视频（1080p, 20Hz）、车载传感器数据（GNSS、IMU、CAN 总线），并标注逐帧语言描述与未来 3 秒轨迹动作（60 帧，全球坐标系下的 (x,y,z) 坐标）。
- 原始数据规模达1000 小时以上，经筛选后形成高质量子集，远超现有同类数据集（如 BDD-X、DRAMA 等）的规模与标注密度（见表 1 对比）。

- 自动化标注与字幕生成 pipeline
  - 轨迹标注：通过卡尔曼滤波融合 GNSS/IMU 数据，自动生成高精度轨迹，并通过启发式方法剔除异常值。
  - 目标检测：采用传感器融合技术（雷达 + 摄像头）检测前车，结合专用模型（OpenLenda-s）识别交通灯状态（含箭头信号）。
  - 自动字幕生成：
    - 规则基字幕：基于车速、加速度、转向角等参数生成结构化描述。
    - VLM 基字幕：利用VideoLLaMA 2模型处理视频片段（60 帧窗口，采样 8 帧），生成包含时空信息的自然语言描述（如天气、风险提示）。
    - 幻觉抑制：以规则基字幕为事实约束，引导 VLM 补充细节（如 “窄路” “湿滑路面”），减少虚构内容。
- 数据多样性与平衡性
  - 通过逆经验分布采样策略，平衡车速、转向角、信号灯等特征的分布，避免数据偏斜。例如，采样后车速分布更均匀，转向角覆盖更广（见图 4），确保模型能处理急弯、加减速等复杂动作。

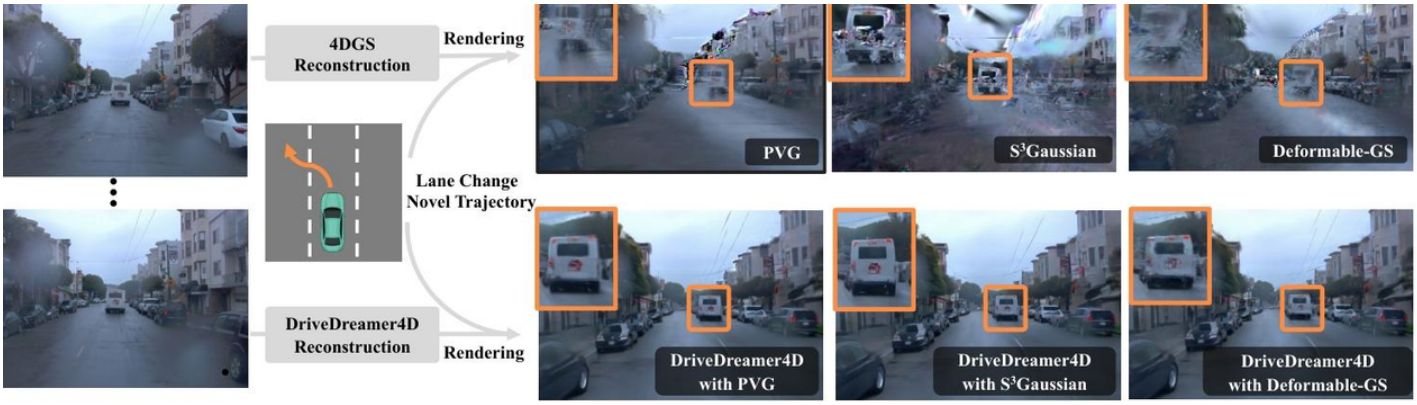
2. 开发 CoVLA-Agent：基于 VLA 模型的可解释端到端自动驾驶系统

- 模型架构创新
  - 融合CLIP 视觉编码器（提取图像特征）、Llama-2 语言模型（处理文本指令与推理）、MLP 层（整合车速等数值信号），实现 “图像输入→语言描述 + 轨迹预测” 的端到端输出。
  - 引入轨迹查询特殊令牌，通过 LLM 生成未来 3 秒的 10 个轨迹点（相对当前位置），并结合均方误差（MSE）损失优化预测精度。
- 多任务联合训练
  - 同时训练场景描述生成与轨迹预测任务，通过加权交叉熵与 MSE 损失联合优化，强化语言与动作的一致性。例如，模型能根据 “右转” 的文本描述生成对应的转向轨迹（见图 6 (d)）。
- 性能验证与可解释性
  - 在测试中，使用 ** 真实字幕（ground truth caption）** 时，轨迹预测的平均位移误差（ADE）为 0.814 米，最终误差（FDE）为 1.655 米，显著优于使用预测字幕的结果（ADE=0.955, FDE=2.239），证明数据标注质量对模型性能的关键影响。

- 模型可生成自然语言推理过程（如 “需注意前车距离”），提升决策透明度，有助于分析错误模式（如因单帧误判导致的方向偏差，见表 3）。

2.8 DriveDreamer4D: World Models Are Effective Data Machines for 4D Driving Scene Representation

(理想)这篇文章提出了 DriveDreamer4D 框架，通过融合自动驾驶世界模型的先验知识，提升了 4D 驾驶场景表示能力，为自动驾驶闭环仿真提供了更真实、多样的场景模拟方案，推动了端到端自动驾驶系统的发展。



gure 1. Previous 4D Gaussian Splatting methods (e.g., PVG [8], S^3Gaussian [26], Deformable-GS [69]) face challenges in rendering

2.8.1 研究背景与问题

- 闭环仿真需求：端到端自动驾驶系统需要闭环仿真来评估算法，但现有方法（如 NeRF、3DGS）依赖正向驾驶场景的训练数据，难以渲染变道、加减速等复杂操作。
- 世界模型的局限：现有自动驾驶世界模型虽能生成多样驾驶视频，但仅输出 2D 视频，缺乏捕捉动态环境时空一致性的能力。

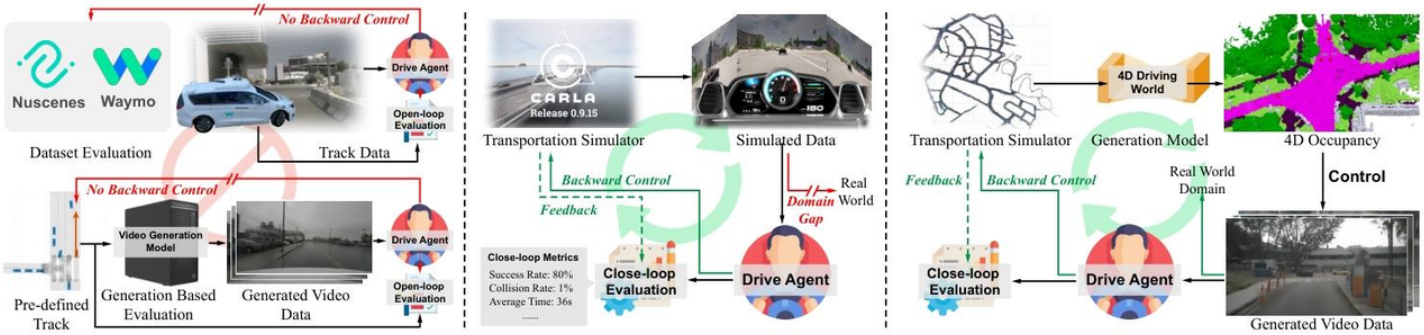
2.8.2 核心方法：DriveDreamer4D 框架

- 新颖轨迹视频生成模块（NTGM）：利用世界模型作为 “数据机器”，通过调整驾驶动作（如转向角、速度）生成新轨迹，并结合结构化条件（3D 边界框、高精地图）控制交通元素的时空一致性，解决复杂场景数据不足的问题。
- 表亲数据训练策略（CDTS）：融合时间对齐的真实与合成数据训练 4D 高斯 splatting（4DGS）模型，引入正则化损失确保感知一致性，缩小数据分布差异，提升模型泛化能力。

2.9 DrivingSphere: Building a High-fidelity 4D World for Closed-loop Simulation

(理想)论文提出DrivingSphere框架，旨在构建高保真闭环自动驾驶仿真环境。其核心通过动态环境合成模块生成包含静态背景与动态物体的 4D 占据网格世界，并利用视觉场景合成模块将其转化为时

空一致的多视角视频。相比传统开环仿真和闭环仿真，DrivingSphere 具备丰富模拟粒度（包含建筑、植被等非交通元素）、物理空间真实性（精确建模 4D 空间交互）和高视觉一致性（ID 感知编码确保跨帧跨视角连贯）。实验表明，其在视觉保真度（FVD 指标 103.42）、开闭环评估（PDMS 0.742，RC 11.7%）等方面显著优于 MagicDrive、DriveArena 等基线方法，有效缩小模拟与真实环境的域差距。

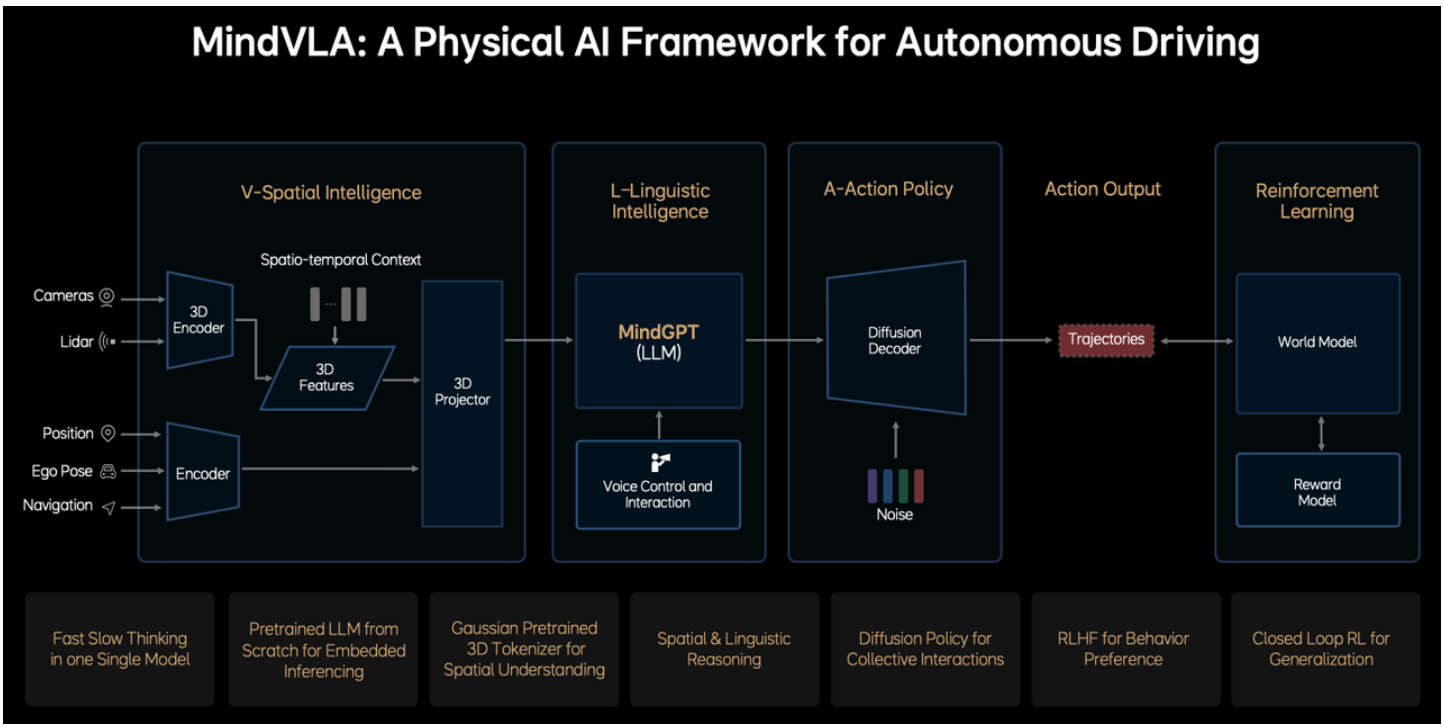


(a) Open-loop Evaluation　(b) Simulated Close-loop Evaluation　(c) Our Generative Closed-loop Simulation

3. 行业进展

3.1 理想

https://static.rainfocus.com/nvidia/gtcs25/sess/1727430977700001r2OJ/FinalPresPDF/S72557_1742210910032001XQ6j.pdf



理想VLA相关论文

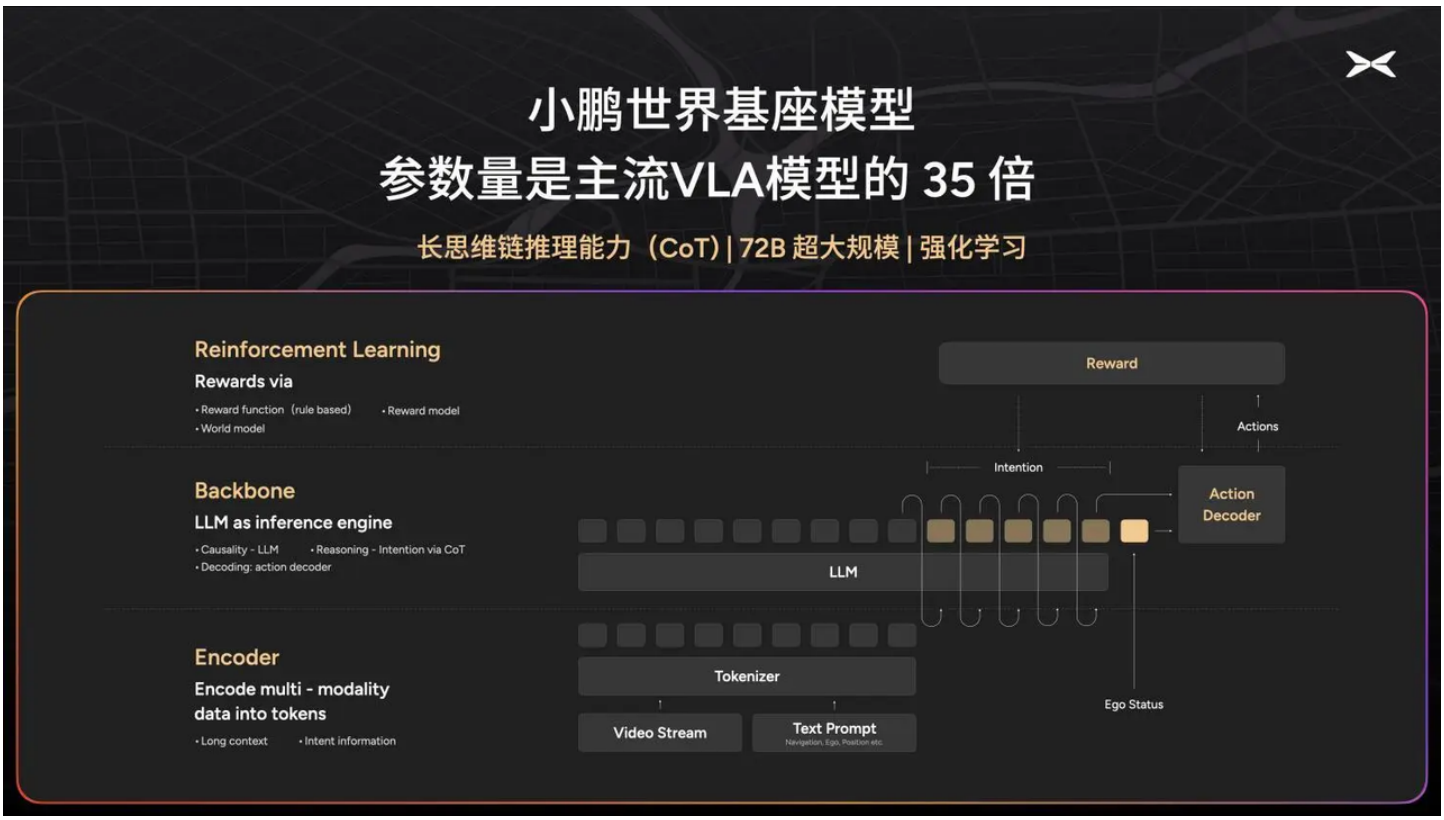
- GaussianAD: Gaussian-Centric End-to-End Autonomous Driving
- Generalizing Motion Planners with Mixture of Experts for Autonomous Driving

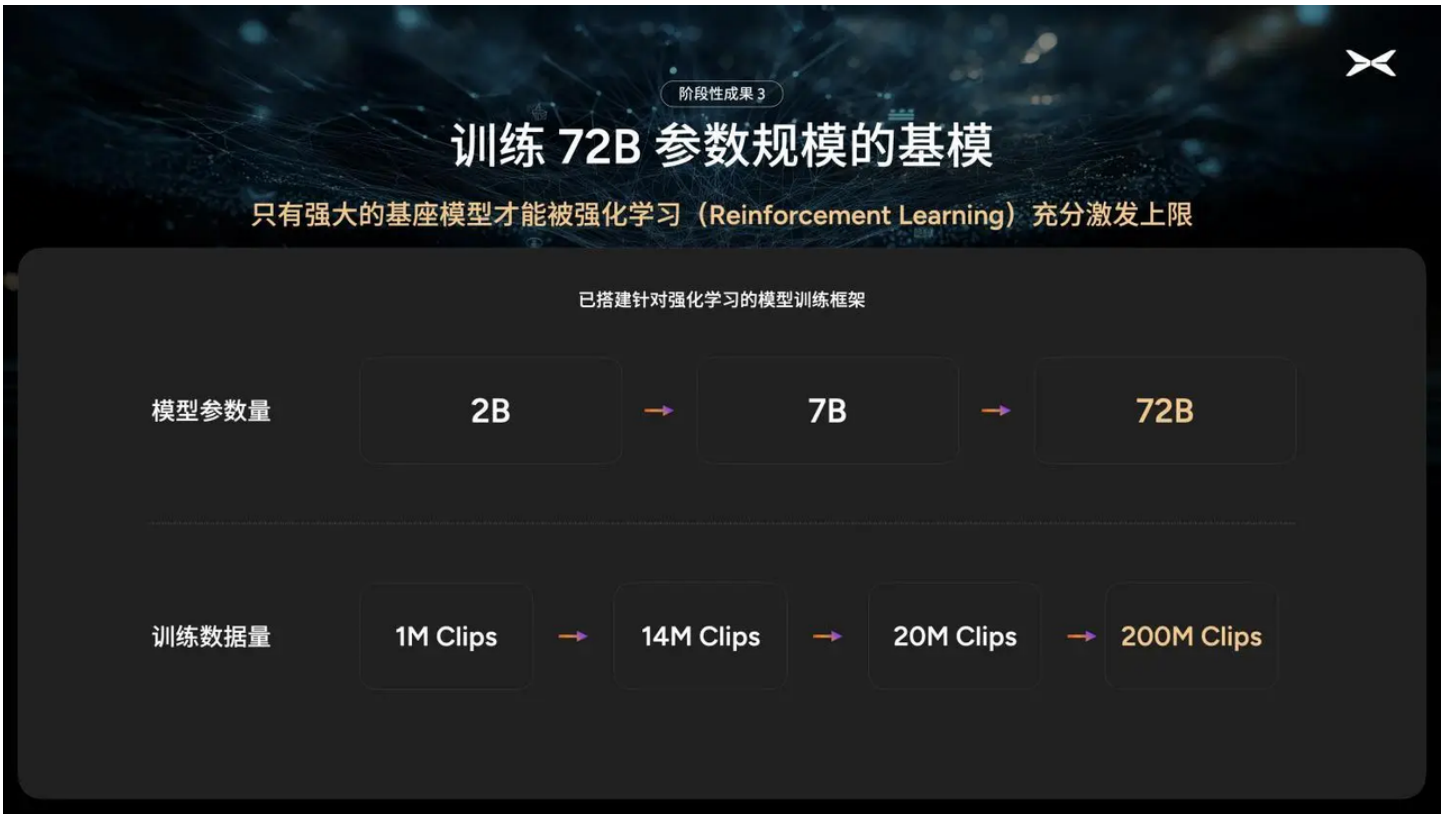
- Preliminary Investigation into Data Scaling Laws for Imitation Learning-Based End-to-End Autonomous Driving
- StreetCrafter: Street View Synthesis with Controllable Video Diffusion Models
- Balanced 3DGS: Gaussian-wise Parallelism Rendering with Fine-Grained Tiling
- ReconDreamer: Crafting World Models for Driving Scene Reconstruction via Online Restoration
- DrivingSphere: Building a High-fidelity 4D World for Closed-loop Simulation
- DriveDreamer4D: World Models Are Effective Data Machines for 4D Driving Scene Representation

3.2 小鹏

小鹏汽车在新X9发布上市之前，做了一场AI技术分享会，再次强调了自己是一家AI驱动的技术公司。而这次技术分享会的一个核心内容就是：小鹏汽车正在研发VLA基座模型，也在研发“世界模型”，而且小鹏汽车已经拥有10 EFLOPS的算力。

可以说，小鹏汽车整个智驾技术路线也已经向业界下一代主流路线VLA开始迭代。





3.3 元戎启行

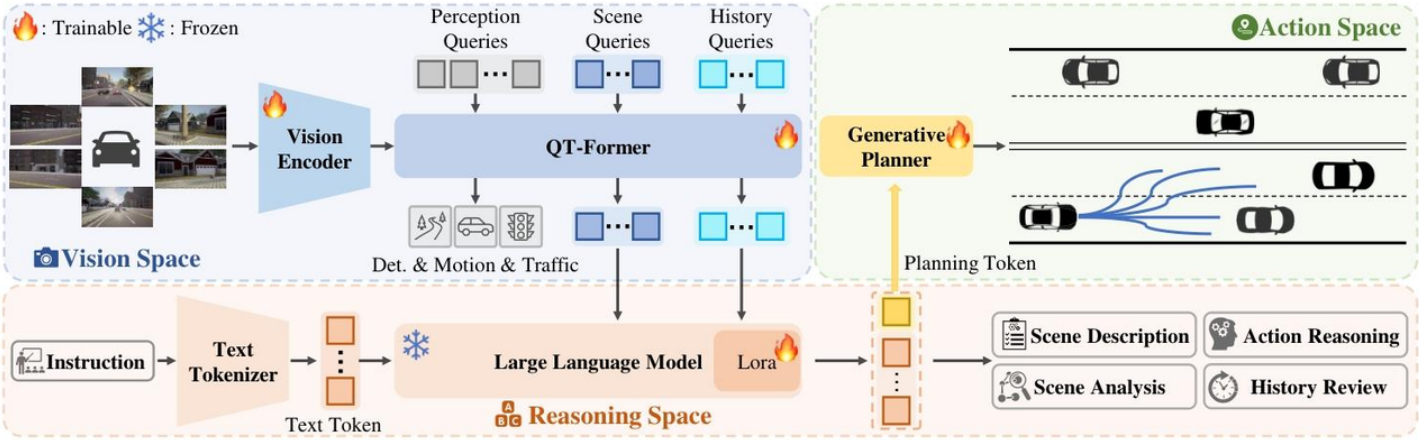
元戎启行则更进一步，于2025年1月22日宣布与某头部车企合作，基于英伟达Thor芯片推出VLA量产车型，计划年内交付消费者，元戎还透露将在Robotaxi领域探索VLA应用，展现了技术普适性的野心。

3月30日，在百人会智能汽车创新技术与产业论坛上，元戎启行CEO周光表示已完成VLA模型（多模态的视觉语言动作模型）的道路测试，并将基于VLA模型打造全系列的智能驾驶系统产品，涵盖激光雷达方案与纯视觉方案，适配多种芯片平台，预计今年将有超5款搭载VLA模型的车型进入消费者市场。周光认为，VLA模型作为当下最先进的技术，使汽车成为了AI智能体，在需求暴涨的背景下，VLA模型将重塑市场格局。https://www.stcn.com/article/detail/1626804.html

3.4 小米

2025年3月中旬，小米汽车与华中科技大学联合发表论文：ORION: A Holistic End-to-End Autonomous Driving Framework by Vision-Language Instructed Action Generation，

提出了一种全新的端到端自动驾驶框架 ORION，旨在解决现有方法在闭环评估中因果推理能力不足的问题。



核心内容：

1. 研究背景与挑战

- 端到端自动驾驶的瓶颈：传统端到端方法在闭环评估中因因果推理能力有限，难以做出正确决策。尽管视觉语言模型（VLM）具备强大的理解和推理能力，但其语义推理空间与动作空间的数值轨迹输出存在鸿沟，导致闭环性能不佳。
- 现有方法的缺陷：
  - 直接文本输出：VLM 不擅长数值推理，且自回归机制无法处理人类规划的不确定性。
  - 元动作辅助：VLM 与经典端到端方法解耦，无法协同优化轨迹和推理过程。

4. 结论-个人观点

- VLA一定不是终级技术
- 数据<Input, action>，是VLA最大的挑战
- VLA是上层技术，最终比拼的还是对于，人，车，场的建模准确度

5. 参考文献

关键Paper

Towards Generalist Robot Learning from Internet Video: A Survey
https://arxiv.org/abs/2404.19664

机器人领域的VLA开山之作RT-2框架 https://arxiv.org/abs/2307.15818 RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control

OpenVLA: An Open-Source Vision-Language-Action Model https://arxiv.org/abs/2406.09246

A Dual Process VLA: Efficient Robotic Manipulation Leveraging VLM
https://arxiv.org/abs/2410.15549

Helix: A Vision-Language-Action Model for Generalist Humanoid Control
https://www.figure.ai/news/helix

A Survey on Vision-Language-Action Models for Embodied AI https://arxiv.org/abs/2405.14093

Survey on Vision-Language-Action Models https://arxiv.org/abs/2502.06851

OpenDriveVLA: Towards End-to-end Autonomous Driving with Large Vision Language Action Model https://arxiv.org/abs/2503.23463

CoVLA: Comprehensive Vision-Language-Action Dataset for Autonomous Driving
https://arxiv.org/html/2408.10845v1

VLA其他相关论文速递

- Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware
- OpenVLA: An Open-Source Vision-Language-Action Model
- TOWARDS SYNERGISTIC, GENERALIZED AND EFFICIENT DUAL-SYSTEM FOR ROBOTIC MANIPULATION
- π0: A Vision-Language-Action Flow Model for General Robot Control
- RDT-1B: A DIFFUSION FOUNDATION MODEL FOR BIMANUAL MANIPULATION
- GR-2: A Generative Video-Language-Action Model with Web-Scale Knowledge for Robot Manipulation
- Diffusion-VLA: Scaling Robot Foundation Models via Unified Diffusion and Autoregression
- DexVLA: Vision-Language Model with Plug-In Diffusion Expert for General Robot Control
- Fine-Tuning Vision-Language-Action Models: Optimizing Speed and Success
- ChatVLA: Unified Multimodal Understanding and Robot Control with Vision-Language-Action Model
- VLM-E2E: Enhancing End-to-End Autonomous Driving with Multimodal Driver Attention Fusion

小米

ORION: A Holistic End-to-End Autonomous Driving Framework by Vision-Language Instructed Action Generation

https://arxiv.org/abs/2503.19755

理想VLA相关论文

- GaussianAD: Gaussian-Centric End-to-End Autonomous Driving
- Generalizing Motion Planners with Mixture of Experts for Autonomous Driving
- Preliminary Investigation into Data Scaling Laws for Imitation Learning-Based End-to-End Autonomous Driving
- StreetCrafter: Street View Synthesis with Controllable Video Diffusion Models
- Balanced 3DGS: Gaussian-wise Parallelism Rendering with Fine-Grained Tiling
- ReconDreamer: Crafting World Models for Driving Scene Reconstruction via Online Restoration
- DrivingSphere: Building a High-fidelity 4D World for Closed-loop Simulation
- DriveDreamer4D: World Models Are Effective Data Machines for 4D Driving Scene Representation

理想VLA技术报告PPT

- https://http://static.rainfocus.com/nvidia/gtcs25/sess/1727430977700001r2OJ/FinalPresPDF/S72557_1742210910032001XQ6j.pdf

Report

具身智能与自动驾驶的结合点：VLA https://db.shujubang.com/home/login/index/gid/21074

小鹏汽车启动VLA基模研发，2亿Clips训练720亿超大规模模型
https://www.sohu.com/a/884287271_116210

小米汽车端到端VLA自动驾驶方案Orion，似乎在diss理想的MindVLA
https://zhuanlan.zhihu.com/p/1890790479802638885

理想全新一代智驾VLA技术方案解读 https://zhuanlan.zhihu.com/p/1885988337225032557

2025年，自动驾驶即将开“卷”的端到端大模型 2.0 - VLA (Vision Language Action)
https://news.qq.com/rain/a/20241222A06QDW00

RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control
https://robotics-transformer2.github.io/assets/rt2.pdf

OpenVLA: An Open-Source Vision-Language-Action Model https://arxiv.org/pdf/2406.09246

https://openvla.github.io/

· 2024 年 Physical Intelligence 发布的 VLA 模型 π0，基于 transformer + 流匹配（flow matching）架构，当前开源领域最强的 VLA 模型之一。 https://mp.weixin.qq.com/s/Hq9iwEKqtJ7n1KY-R-4XZA

理想贾鹏GTC 2025讲VLA完整视频（带字幕） https://www.bilibili.com/video/BV11yX5Y9EEj/?vd_source=115911bd71b74bfcc0cad43e576887e4